Transkriptomanalyse

11. November 2026, Sommersemester 2025

Aufgabe 2

Der gesamte R-Code für die Lösung von Aufgabe 1 ist in der Datei `.R` zu finden.

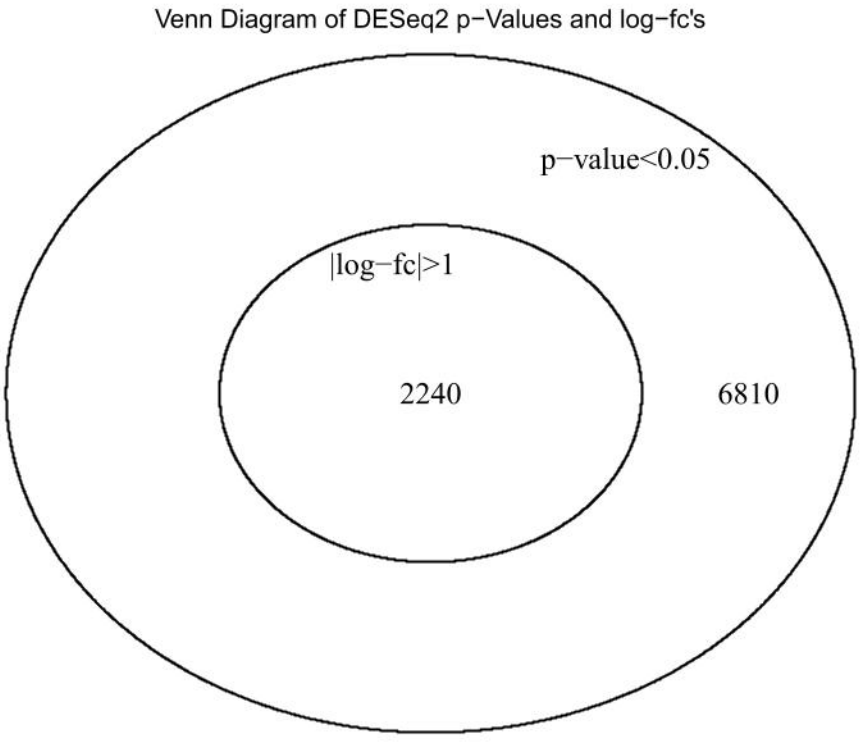
a)

$\alpha = 0.05$
erste 3 p-Werte: $7.3734 \cdot 10^{-21}$, $1.9222 \cdot 10^{-20}$, $2.2198 \cdot 10^{-20}$
log-fc's zu den p-Werten: 3.0516, 8.8602, 6.7671
Die kleinsten 3 p-Werte von DESeq2 sind sehr viel kleiner als die mit dem t-Test aus der Vorlesung berechneten.

b)

Anzahl der p-Werte < 0.05 (ohne Korrektur): 9050

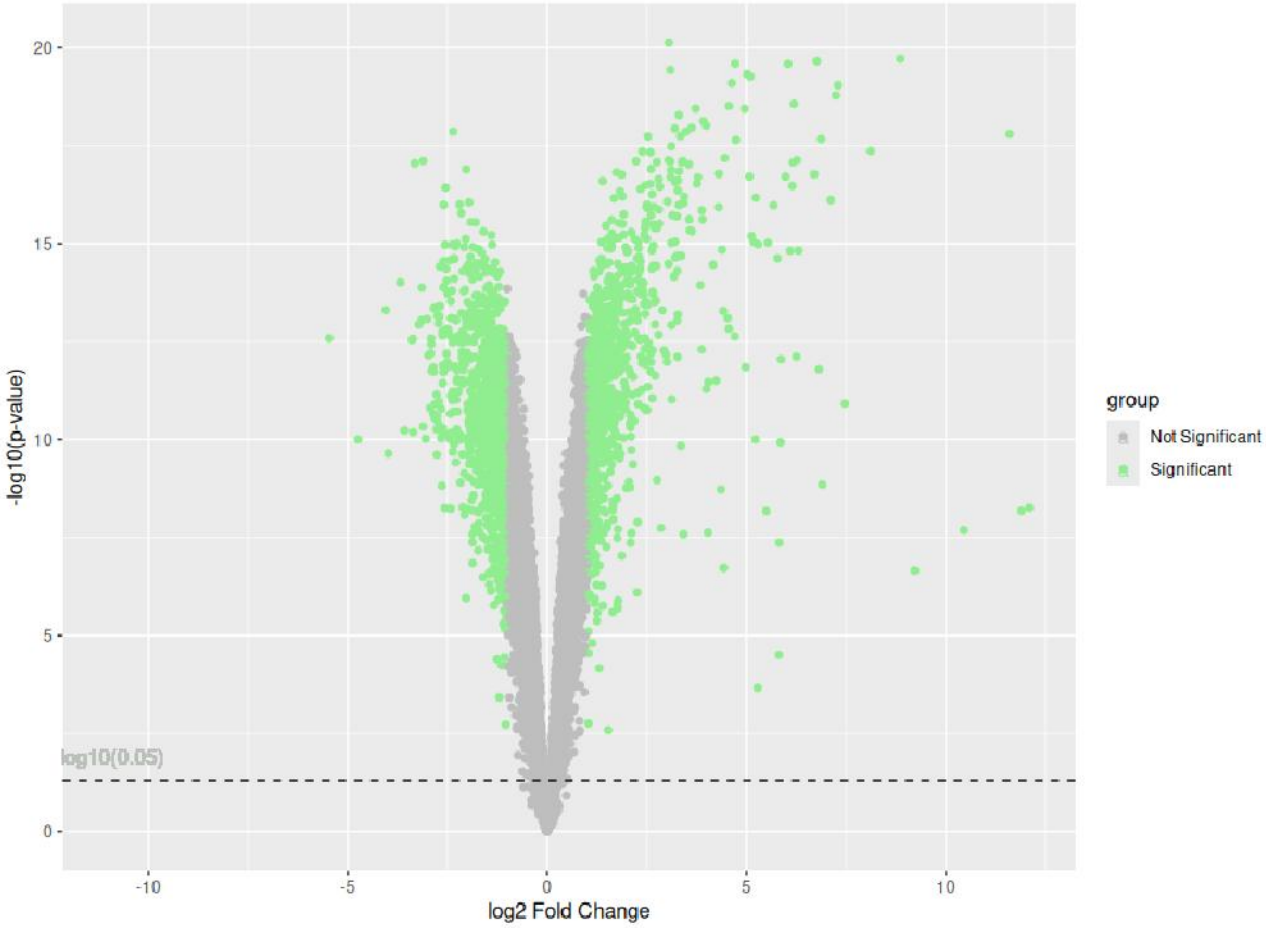
Anzahl der Beträge der log-fc's > 1 (ohne Korrektur): 2240



Bei DESeq2 sind weniger p-Werte signifikant, als bei den selbst berechneten, der Unterschied ist mit einer Differenz von 124 relativ gering. Die Anzahl der Beträge der Log-Fold-Changes, welche größer 1 sind, unterscheidet sich nur um 1 von den selbst berechneten.

Insgesamt zeigt sich auch hier, dass alle Gene, deren Log-Fold-Change im Betrag größer ist als 1 sind auch die Bedingung für den p-Wert erfüllen, während es deutlich mehr "signifikante" p-Werte gibt, deren Gene die Bedingung des Log-Fold-Changes nicht erfüllen.

c)



Alle grauen Punkte auf dem Plot zeigen an, dass diese Gene die Bedingung des Log-Fold-Change und/oder der p-Wert Einschränkung nicht erfüllen und somit nicht als signifikant eingestuft würden. Genau wie in Aufgabe b) ist hier zu erkennen, dass theoretisch der Log-Fold-Change "genügt" um, die letztendliche Genmenge zu begrenzen, da das Signifikanzniveau von 0.05 von keinem Gen unterschritten wird, das nicht ohnehin schon durch den Grenzwert des Log-Fold-Changes heraussortiert worden wäre. Das bedeutet, dass sinnvollerweise eine Korrekturmethode auf den Schwellwert angewendet werden sollte, um nicht zu viele falsch-positive Ergebnisse zu erhalten.

d)

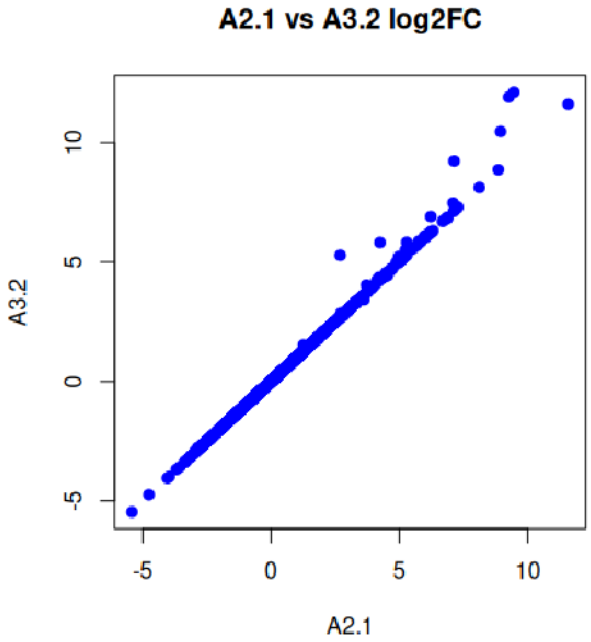
FWER-Korrekturverfahren	Anzahlen der differenziell-exprimierten Gene
Sidak	5499
Bonferroni	5492
Holm-Sidak	5792
Holm-Bonferroni	5773
Hochberg	5773
FDR-Korrekturverfahren	
Benjamini-Hochberg	8968
Benjamini-Yekutieli	7989
ohne Korrekturverfahren	9050

Tabelle 1

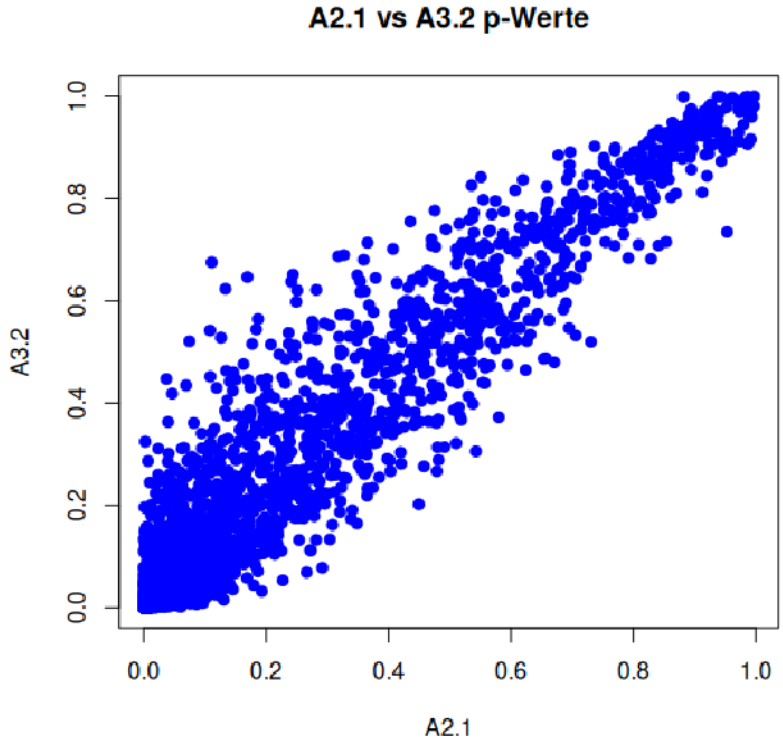
Bei den FWER-Korrekturverfahren sind mit den Werten von DESeq2 generell sehr viel mehr Gene differenziell-exprimiert als mit den selbst berechneten p-Werten.
Die beobachteten Ergebnisse entsprechen den Erwartungen bezüglich der Korrekturverfahren. Die FWER-Korrekturen wie Bonferroni und Sidak sind streng und führen zu einer deutlich geringeren Anzahl an differentiell exprimierten Genen. Die Holm-Verfahren und Hochberg sind leicht weniger konservativ, was zu einer moderat höheren Zahl an signifikanten Genen führt. Holm-Bonferroni und Hochberg kommen hier zum gleichen Ergebnis. Die FDR-Korrekturen (Benjamini-Hochberg, Benjamini-Yekutieli) erlauben eine höhere Anzahl an signifikanten Genen, da sie nur die Fehlerrate unter den entdeckten Genen kontrollieren und nicht für alle Tests gleichzeitig. Die strikteste Korrektur (Bonferroni) hat auch wie zu erwarten die wenigsten Gene als differentiell exprimiert markiert (5492).

e)

Der Scatterplot vergleicht die Log2-Fold-Changes der Aufgaben 2.1 und 3.2. Die Punkte liegen nahezu auf einer Diagonalen, was eine starke positive Korrelation zwischen den beiden Berechnungen anzeigt. Dies bedeutet, dass die Log2-Fold-Changes weitgehend übereinstimmen.
Vereinzelte Abweichungen von der Diagonalen deuten jedoch darauf hin, dass einige Gene unterschiedlich stark bewertet wurden, was möglicherweise auf unterschiedliche Normalisierungsansätze oder leichte Unterschiede in der Testmethodik zurückzuführen ist. Insgesamt bestätigen die Ergebnisse jedoch die sehr starke Ähnlichkeit der Analyse zwischen den beiden Aufgaben.


A2.1 vs A3.2 log2FC
A3.2
10
5
0
-5
-5
0
5
10
A2.1

f)


A2.1 vs A3.2 p-Werte
A3.2
1.0
0.8
0.6
0.4
0.2
0.0
0.0
0.2
0.4
0.6
0.8
1.0
A2.1

Es ist eine deutliche positive Korrelation zu erkennen: Gene mit niedrigem p-Wert in einer Aufgabe tendieren dazu, auch in der anderen Aufgabe niedrige p-Werte zu haben. Die Punkte sind jedoch nicht perfekt entlang der Diagonalen verteilt, sondern streuen relativ stark, was auf Unterschiede zwischen den Berechnungs-/Modellierungsverfahren hinweisen könnte. Insgesamt haben die p-Werte aus beiden Aufgaben jedoch eine ähnliche Tendenz.

g)

Die teilweise recht großen Unterschiede in den p-Werten lassen sich damit begründen, dass DESeq2 eine angepasste Modellierung der Daten auf Basis der Negativen Binomialverteilung nutzt, was zu anderen p-Werten führen kann.
Die Anzahl der Gene mit einem p-Wert kleiner 0.05 unterscheidet sich nur leicht zwischen den Ansätzen: In Blatt 2 wurden 9174 Gene als signifikant eingestuft, während es mit DESeq2 9050 Gene waren. Die Zahl der Gene mit einem Betrag des Log2-Fold-Changes größer 1 war in beiden Ansätzen nahezu identisch (Blatt 2: 2241 Gene, Blatt 3: 2240 Gene). Dies deutet darauf hin, dass die stärksten Expressionseffekte durch beide Methoden konsistent erkannt werden.
Im Venn-Diagramm sowie im Volcano-Plot aus beiden Blättern wird sichtbar, dass Gene mit großem |Log2-Fold-Change| (>1) durchgehend auch als signifikant hinsichtlich ihrer p-Werte erkannt werden.
Die Ergebnisse der Multiple-Test-Korrekturen (Teilaufgabe d) zeigen jedoch größere Unterschiede: Während bei der Auswertung in Blatt 2 sehr strikte Korrekturverfahren zu einer starken Reduktion der Anzahl signifikanter Gene führten (z.B. 3039 nach Bonferroni-Korrektur), wurden mit DESeq2 erheblich mehr Gene als differentiell exprimiert identifiziert (z.B. 5492 nach Bonferroni-Korrektur). Auch die FDR-Methoden (Benjamini-Hochberg und Benjamini-Yekutieli) führten bei DESeq2 zu noch höheren Zahlen an entdeckten Genen.
Die Scatterplots der Log2-Fold-Changes (Teilaufgabe e) und der p-Werte (Teilaufgabe f) bestätigen diese Beobachtungen: Die Log2-Fold-Changes aus Aufgaben 2.1 und 3.2 korrelieren sehr stark, was auf eine hohe Übereinstimmung der gefundenen differentiellen Effekte hinweist. Die p-Werte zeigen ebenfalls eine deutliche, aber deutlich weniger perfekte Korrelation, was Unterschiede in der statistischen Teststrategie widerspiegelt.
Insgesamt zeigt der Vergleich, dass DESeq2 robustere und sensitivere Ergebnisse liefert, insbesondere bei der Erkennung von differentiell exprimierten Genen mit kleinen Effektgrößen könnte das von Nutzen sein.