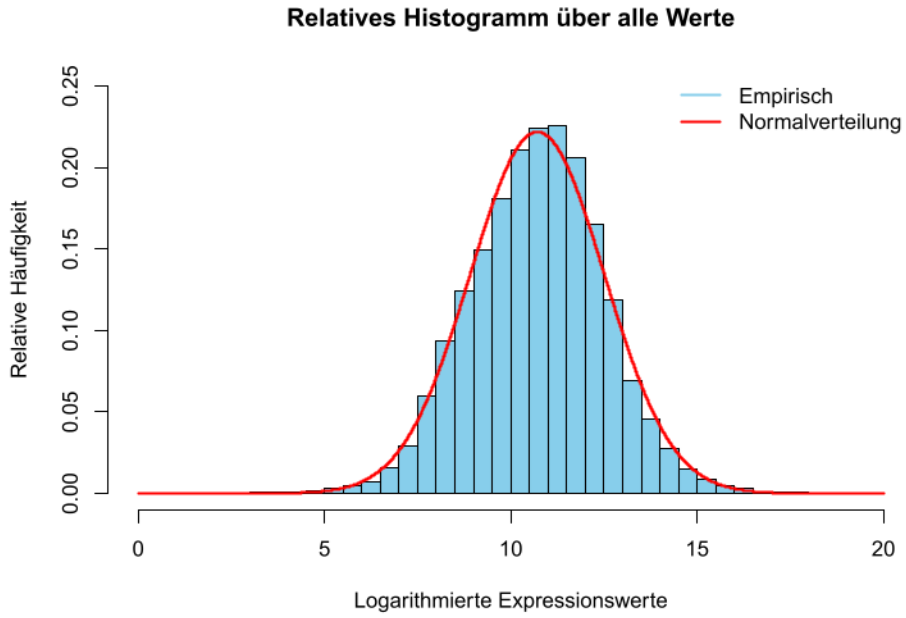
Transkriptomanalyse

13. April 2025, Sommersemester 2025

Aufgabe 2

Der Gesamte R-Code für die Lösung von Aufgabe 1 ist in der Datei `Uebung1_A1.R` zu finden.

a)



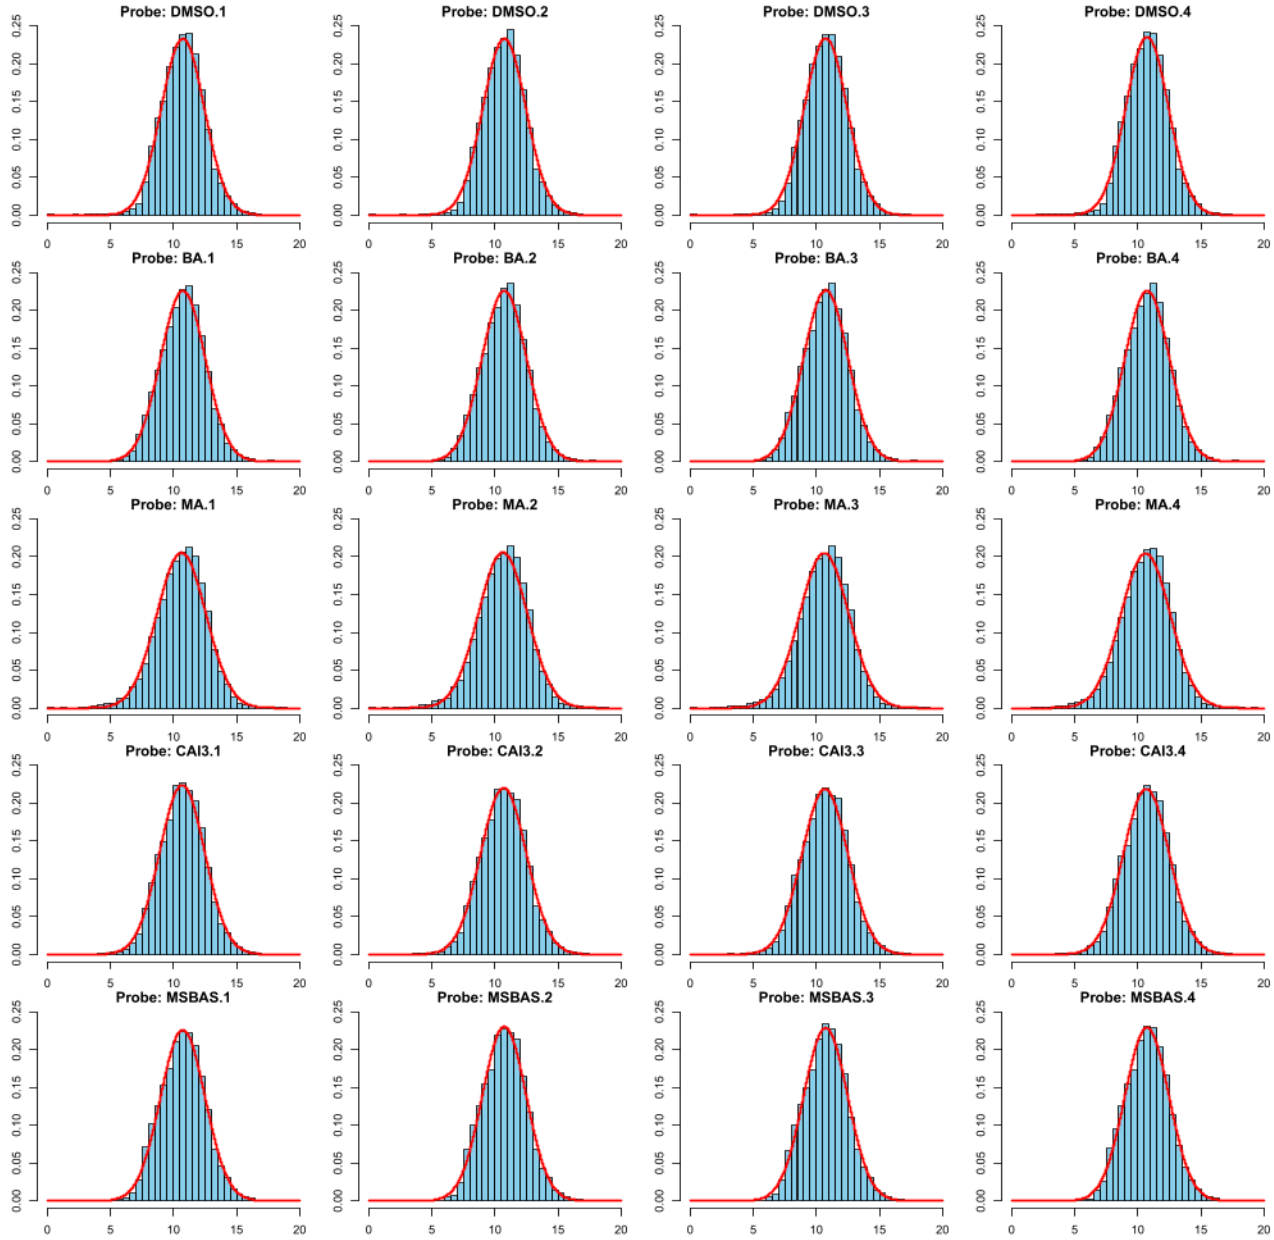
MLE-Parameter:

$$\mu = 10,7107$$
$$\sigma = 1,798102$$

Auch wenn es leichte Abweichungen gibt – insbesondere im Bereich zwischen den logarithmierten Expressionswerten 11 und 13 – beschreibt die Normalverteilung mit den empirisch ermittelten Parametern die Daten insgesamt gut. Die Verteilung zeigt eine glockenförmige, symmetrische Struktur ohne starke Ausreißer und entspricht weitgehend der theoretischen Dichtefunktion. Die beobachtete Überhäufigkeit im mittleren Bereich lässt sich empirisch begründen, was die Eignung der Normalverteilung als Approximationsmodell nicht ausschließt.

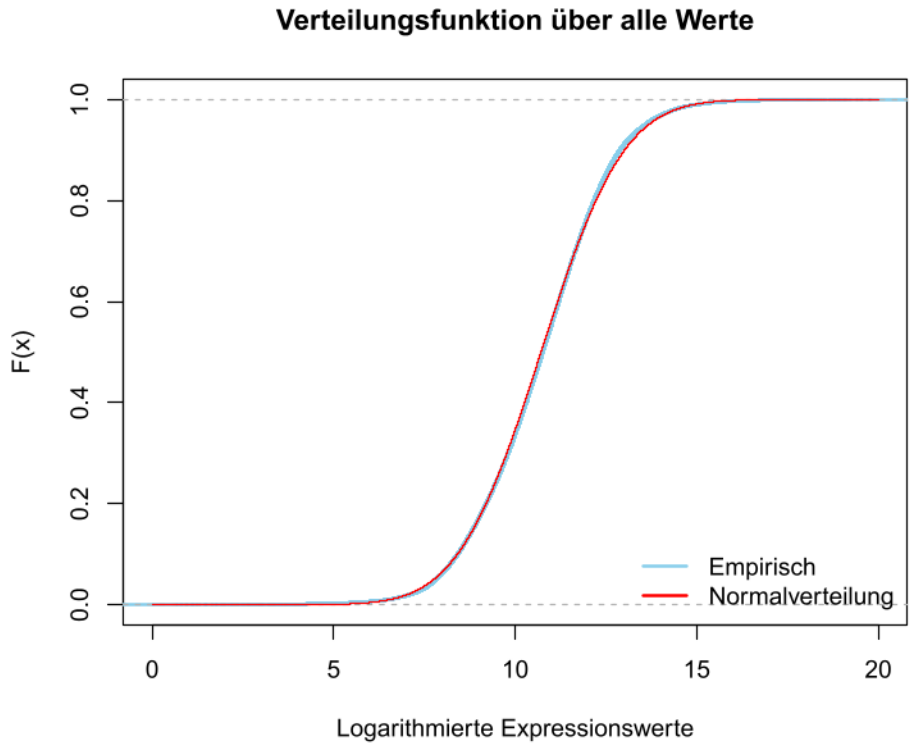
b)

(Um die Plots hier erkennbarer zu machen wurden die zusätzlichen Achsenbeschriftungen nicht geplottet, die Wertebereiche sind jedoch gleich und alle Plots haben auf der x-Achse die log. Expressionswerte und auf der y-Achse die relativen Häufigkeiten.)



Insgesamt ähneln sich die Verteilungen der einzelnen Proben untereinander sowie im Vergleich zum Gesamthistogramm stark. Es zeigen sich nur wenige Ausreißer, sodass die Annahme einer Normalverteilung hier für alle Proben gerechtfertigt ist. Die Unterschiede zwischen den einzelnen Behandlungen sind ebenfalls sehr gering. Auffällig ist nur, dass der Peak für die MA-Behandlung etwas flacher und breiter erscheint.

c)

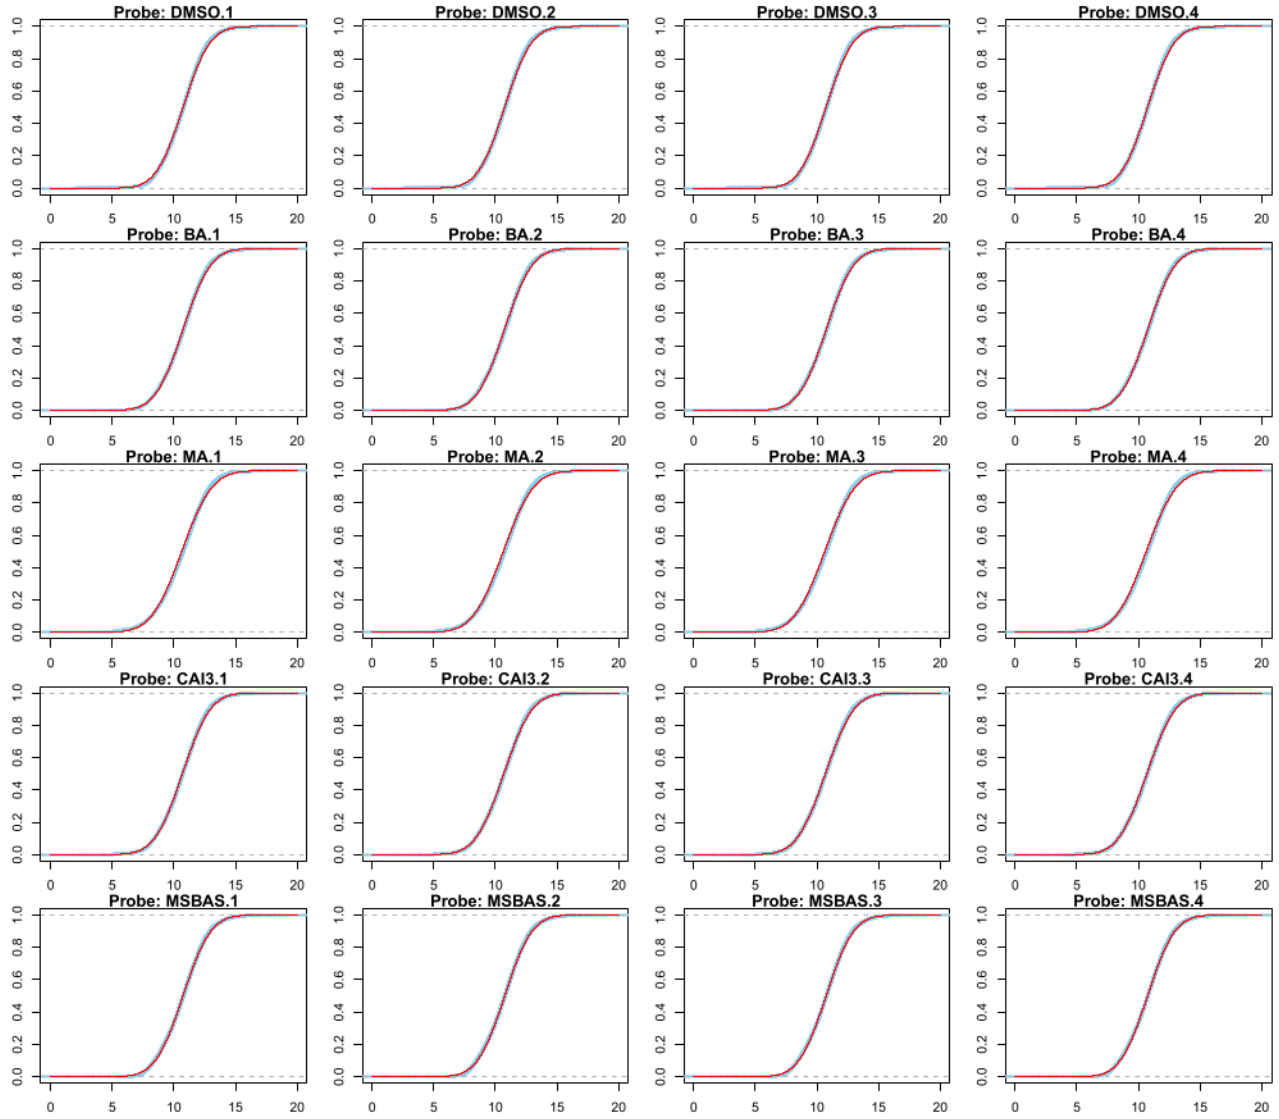


Insgesamt zeigt sich eine sehr gute Übereinstimmung der empirischen und der theoretischen "Kurve". Die theoretische Verteilungsfunktion folgt der empirischen Kurve über den gesamten Wertebereich hinweg sehr eng. Kleinere Abweichungen sind lediglich im unteren und oberen Bereich der Verteilung zu beobachten, was typischerweise auf Randbereiche mit geringerer Datenverfügbarkeit zurückzuführen ist (also übermäßig hohe bzw. niedrige Expressionswerte). Diese Unterschiede fallen jedoch nicht stark ins Gewicht und zeigen, dass die Normalverteilung auch hier für die approximation geeignet ist.

Damit bestätigt auch dieser Plot das Ergebnis aus Aufgabe a).

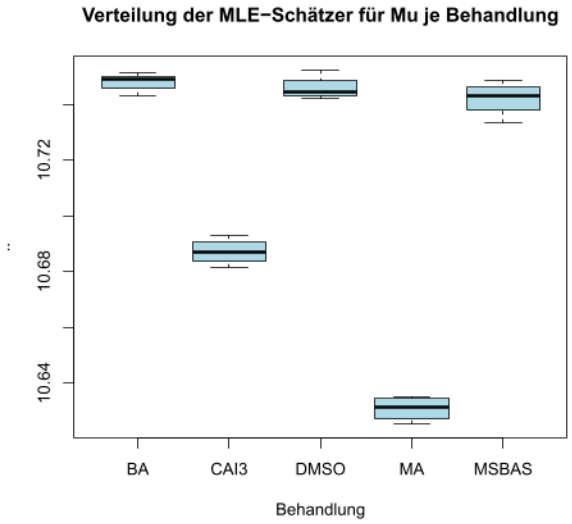
d)

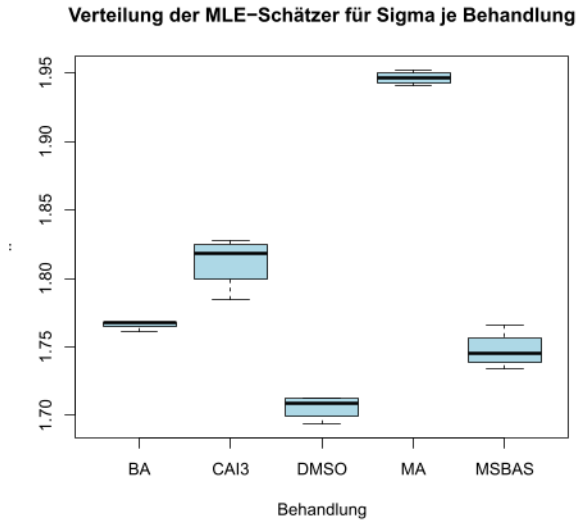
(Um die Plots hier erkennbarer zu machen wurden die zusätzlichen Achsenbeschriftungen nicht geplottet, die Wertebereiche sind jedoch gleich und alle Plots haben auf der x-Achse die log. Expressionswerte und auf der y-Achse die relativen Häufigkeiten.)



Die empirischen Verteilungsfunktionen der einzelnen Proben stimmen weitgehend mit den jeweiligen theoretischen Normalverteilungsfunktionen überein. Nur in wenigen Fällen sind kleinere Abweichungen sichtbar. Die Darstellung zeigt insgesamt, dass die Annahme der Normalverteilung auch auf der Ebene einzelner proben gut begründbar ist.

e)





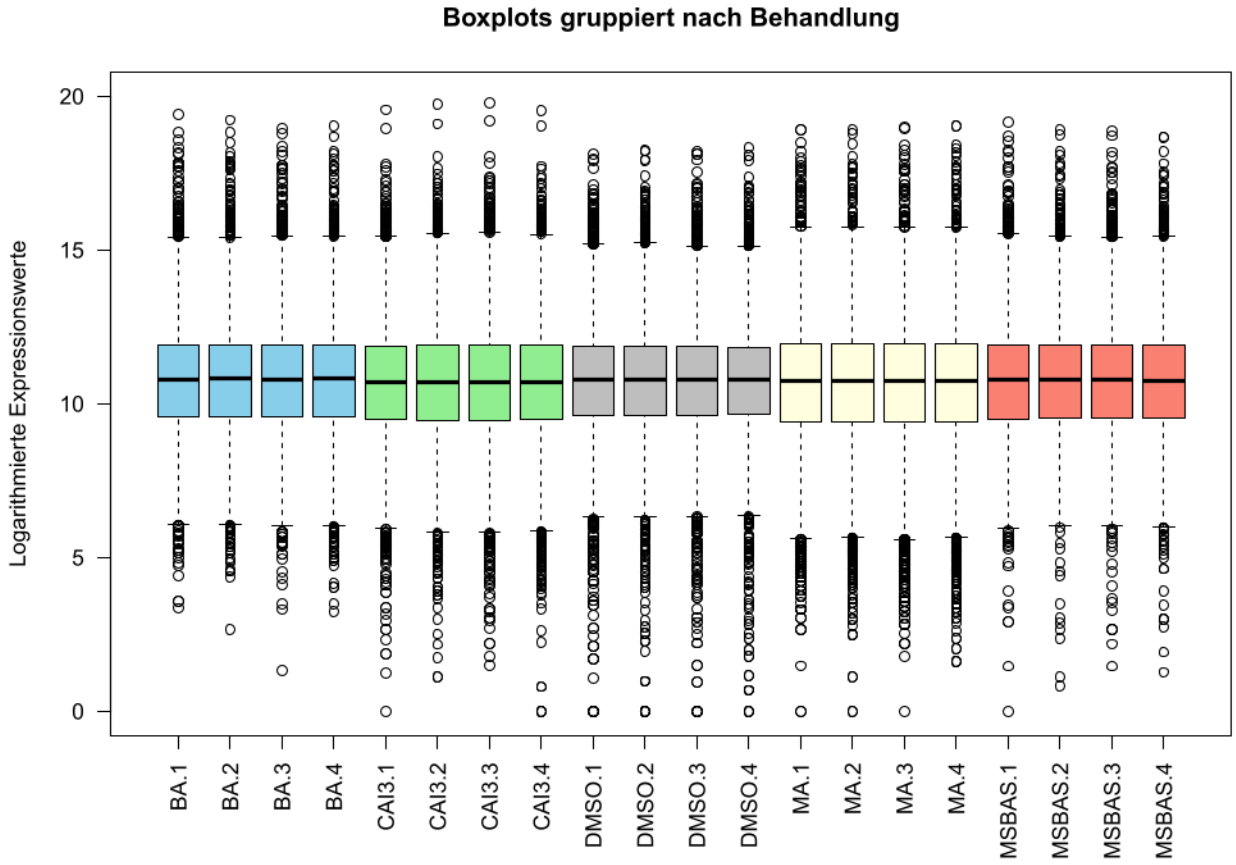
Der Vergleich der MLE-Schätzwerte für μ und σ zeigt, dass sich die Mittelwerte der log-transformierten Expressionsdaten sowohl zwischen den Behandlungsgruppen als auch innerhalb der Gruppen nur geringfügig unterscheiden.

Während sich die μ-Werte für BA, DMSO und MSBAS in einem engen Bereich um etwa 10,74 bewegen, liegen die Werte für CAI3 (ca. 10,68–10,70) und MA (ca. 10,62–10,64) leicht darunter. Die Verteilung der Schätzwerte innerhalb der Gruppen (sichtbar an der Boxplot-Höhe) ist insgesamt gering, wobei BA die geringste Streuung aufweist.

Auch bei den MLE-Schätzern für σ ergibt sich ein ähnliches Bild: BA, DMSO und MSBAS zeigen vergleichbare, eher niedrigere Werte und liegen näher beieinander. CAI3 weist tendenziell höhere σ-Werte auf, wobei die Schätzwerte dort auch deutlich breiter streuen. Besonders auffällig ist die geringe Streuung innerhalb der MA-Proben, deren σ-Werte insgesamt relativ hoch ausfallen. Auch bei BA ist die Streuung ebenfalls sehr gering.

Die Unterschiede zwischen den Gruppen könnten biologisch relevant sein, da sie auf unterschiedliche Wirkstärken oder Wirkmechanismen der getesteten Chemotherapeutika hinweisen könnten. Besonders auffällig sind hier die relativ hohen und konstanten σ-Werte und die relativ niedrigen konstanten μ-Werte der MA-Proben im Vergleich zur Kontrollgruppe. Allerdings liegen alle Werte immer noch in der ähnlichen Bereichen, was Tendenzaussagen erschwert.

f)



Die Darstellung zeigt, dass sich die Verteilungen der logarithmierten Expressionswerte innerhalb der jeweiligen Behandlungsgruppen in Form und Lage insgesamt sehr ähneln. Auch im Vergleich zwischen den Gruppen liegen die Medianwerte nah beieinander, und die Spannweiten der Verteilungen sind weitgehend vergleichbar.

Auffällig ist lediglich, dass die Kontrollgruppe (DMSO) eine kleinere Spannweite der Quantile aufweist, während die MA-Proben insgesamt eine etwas größere Streuung zeigen.

Im Vergleich zu den Ergebnissen aus Aufgabe (e), in der die MLE-Schätzer für μ und σ analysiert wurden, bestätigt sich dieses Muster: Die Unterschiede zwischen den Gruppen sind insgesamt gering. Die Quantile der Proben und die Mittelwerte unterscheiden sich kaum und in der Streuung deuten sich nur geringfügig Unterschiede an (beim Vergleich von DMSO und MA).

g)

Die realen (nicht-transformierten) Expressionswerte bewegen sich häufig über mehrere Größenordnungen hinweg, was zu einer stark schiefen Verteilung führt und die visuelle Darstellung sowie die statistische Modellierung erschwert.

Durch das Logarithmieren werden diese extremen Unterschiede reduziert, sodass auch bei sehr großen Wertunterschieden die Gesamtverteilung besser erfasst werden kann. Da die Rohdaten typischerweise log-

normalverteilt sind, führt die Log-Transformation zu annähernd normalverteilten Werten. Dies erleichtert nicht nur die Analyse der Parameter der Verteilung, sondern ist auch entscheidend für weiterführende Auswertungen, etwa zur Bestimmung differentiell exprimierter Gene. Hierbei wird beispielsweise der Log-Fold-Change verwendet, um Unterschiede quantitativ zu erfassen.