Transkriptomanalyse

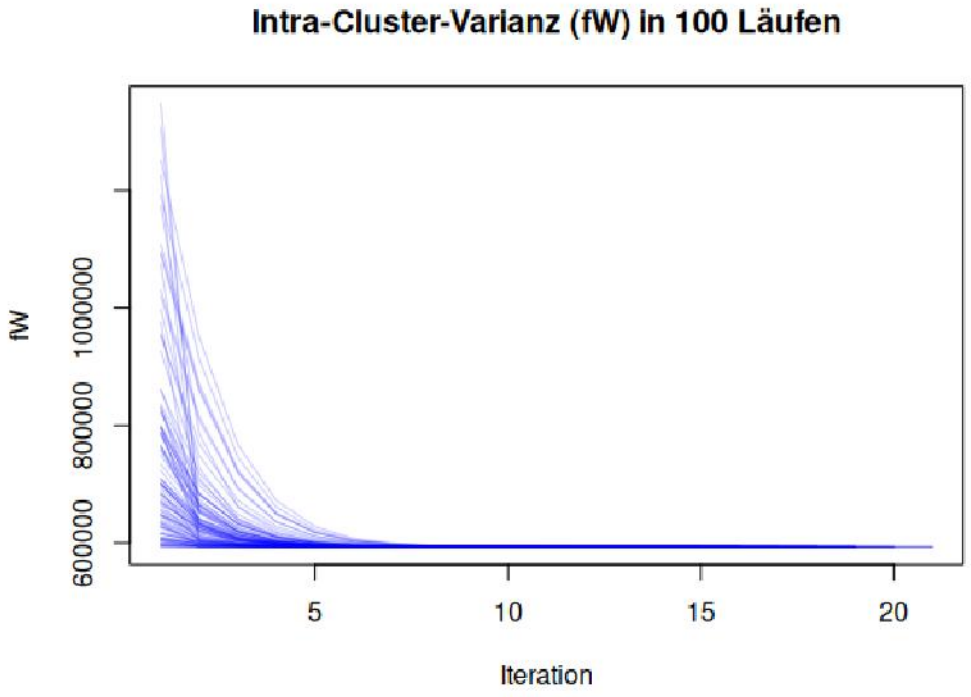
11. November 2026, Sommersemester 2025

Aufgabe 1

Der R-Code für die Lösung von Aufgabe 8.1 ist in der Datei `U8_A1.R` zu finden.

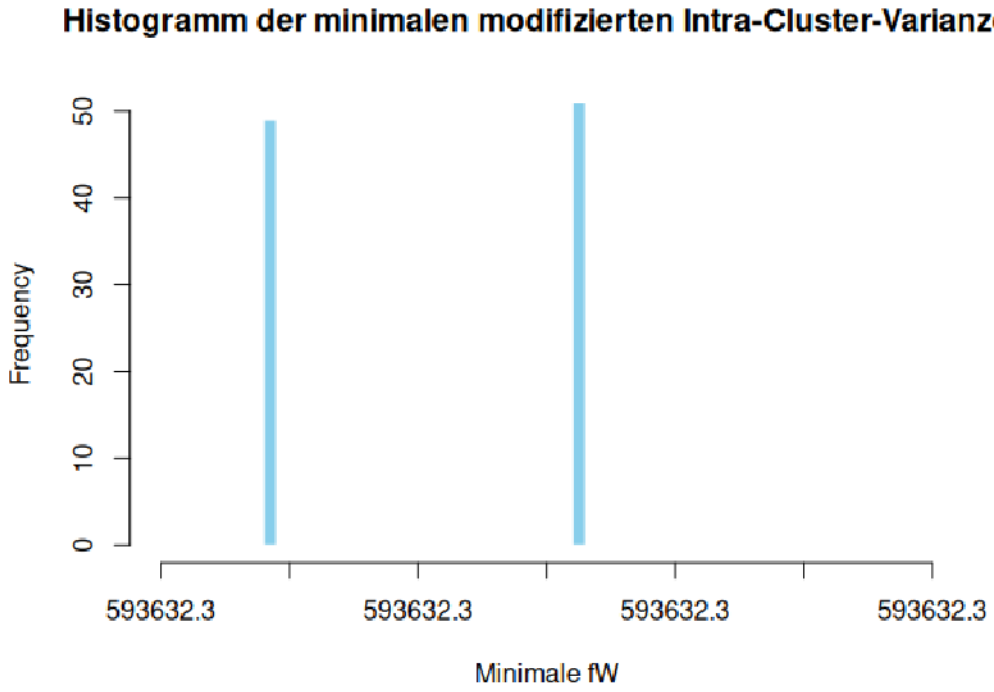
a)

Zur Initialisierung des K-Means-Algorithmus wurden zufällig Genindizes ausgewählt, und deren Werte als Startzentren festgelegt. Als Abbruchkriterium wurde – wie in der Vorlesung besprochen – definiert, dass der Algorithmus endet, sobald sich die Zuordnung der Gene nicht mehr ändert oder eine maximale Anzahl an Iterationen erreicht ist.

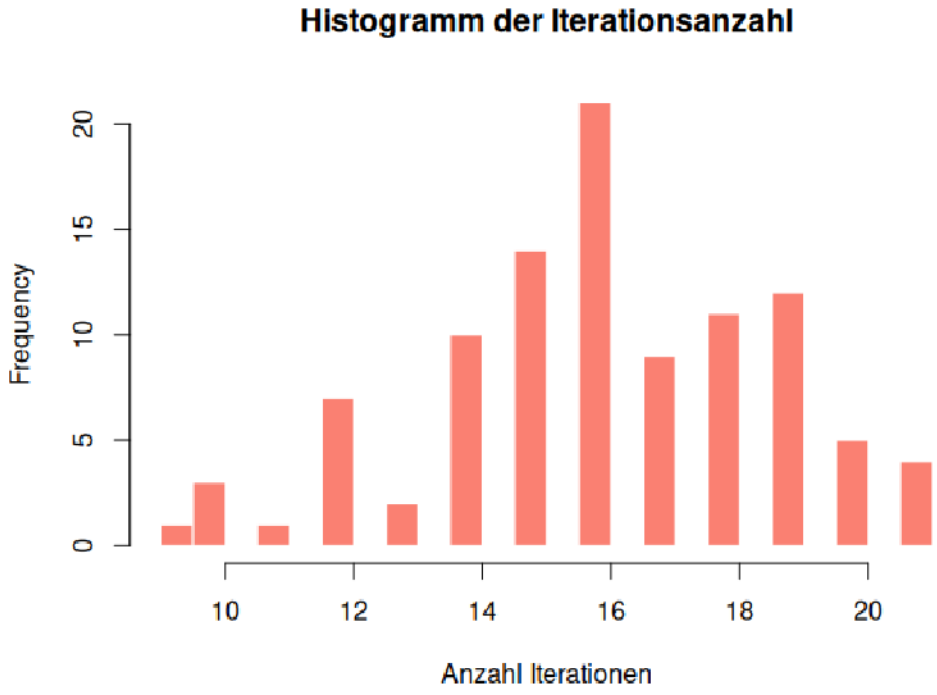


Es ist deutlich zu erkennen, dass die (modifizierte) Intra-Cluster-Varianz mit zunehmender Iterationszahl monoton abnimmt – ein Verhalten, das die theoretische Erwartung bestätigt und zeigt, dass der Algorithmus wie vorgesehen funktioniert.
Betrachtet man das Histogramm der minimalen Intra-Cluster-Varianzen, wird deutlich, dass die Werte sehr dicht beieinander liegen und sich lediglich in der zweiten Nachkommastelle unterscheiden. Auffällig ist zudem, dass das Histogramm jeweils nur zwei ausgeprägte Peaks aufweist. Dies könnte darauf hinweisen, dass die unterschiedlichen Initialisierungen des Algorithmus immer bei 2 verschiedenen Clusterings terminieren, was gute Robustheit und eindeutige Clustering-Lösungen bedeuten würde.

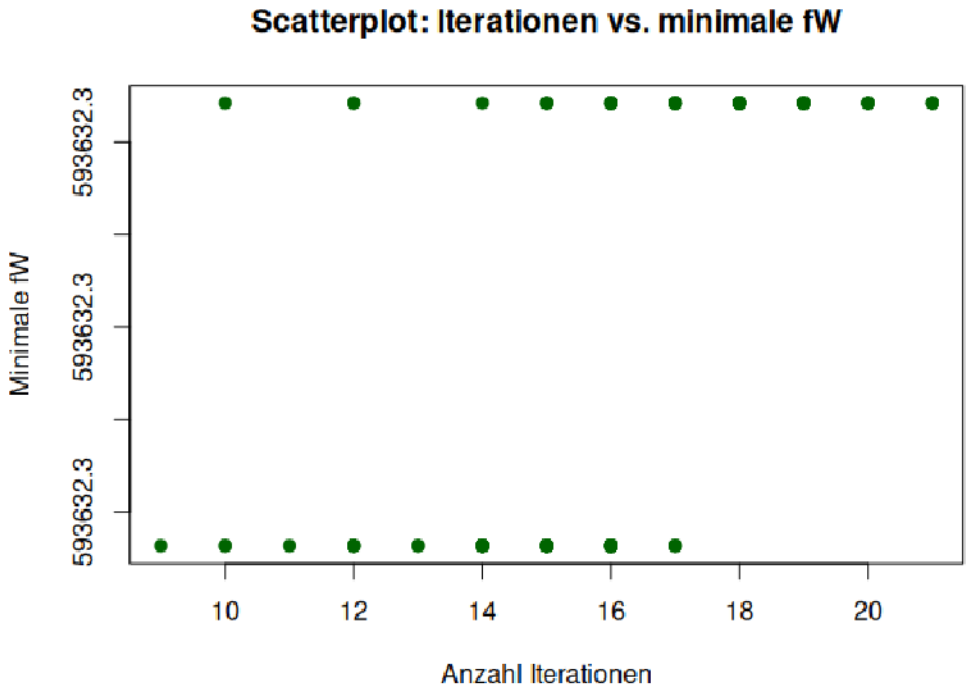
Die fW besteht aus der Summe der Varianzen innerhalb der Cluster, welche dann mit der Anzahl der Punkte im jeweiligen Cluster skaliert, aufsummiert werden. fW skaliert also mit der Anzahl der Datenpunkte. Außerdem ist die Anzahl der Cluster relativ gering, wodurch die Varianzen innerhalb der Cluster groß werden. Daher ist es nicht verwunderlich, dass fW im 6-Stelligen Bereich ist.



Die Anzahl der benötigten Iterationen variiert deutlich stärker als die minimale Intra-Cluster-Varianz. Sie liegt im Bereich von 8 bis 21 und folgt in ihrer Verteilung näherungsweise einer Normalverteilung mit einem Mittelwert von etwa 16.

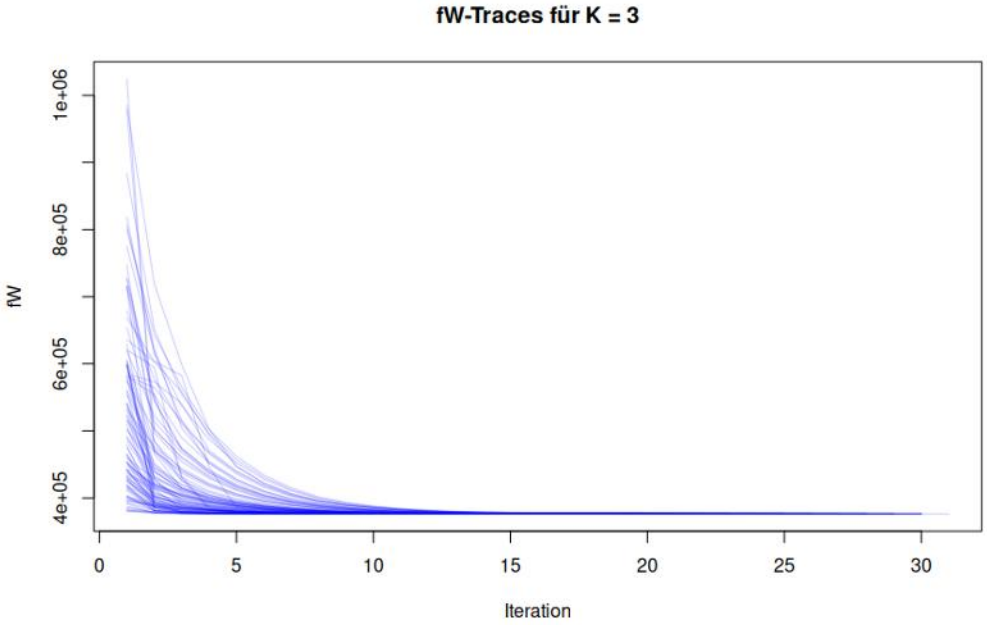


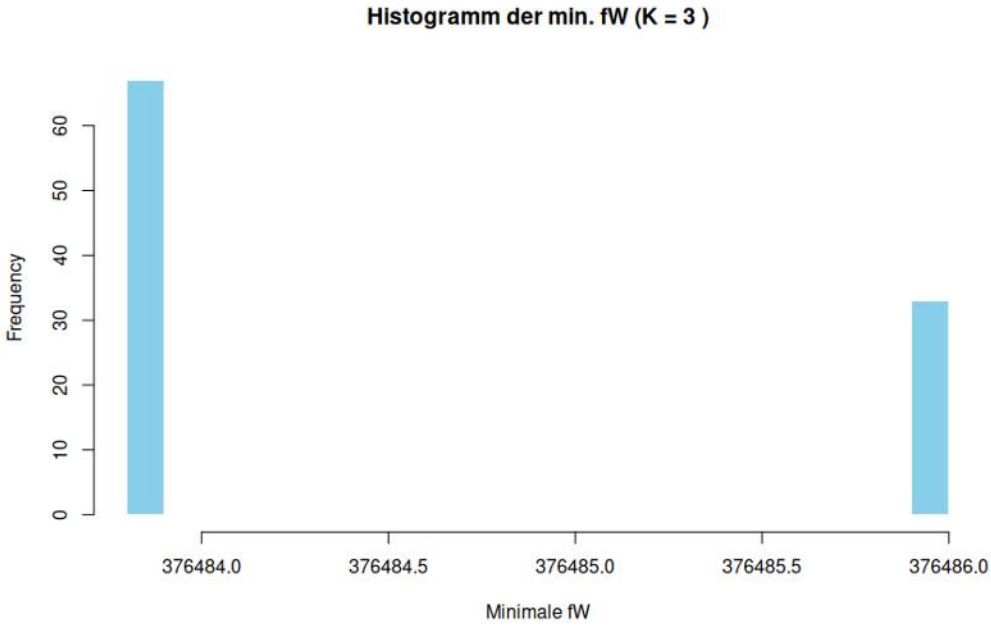
Im Scatterplot lässt sich eine leichte Tendenz erkennen: Läufe mit weniger Iterationen führen tendenziell zu einer geringeren Intra-Cluster-Varianz.

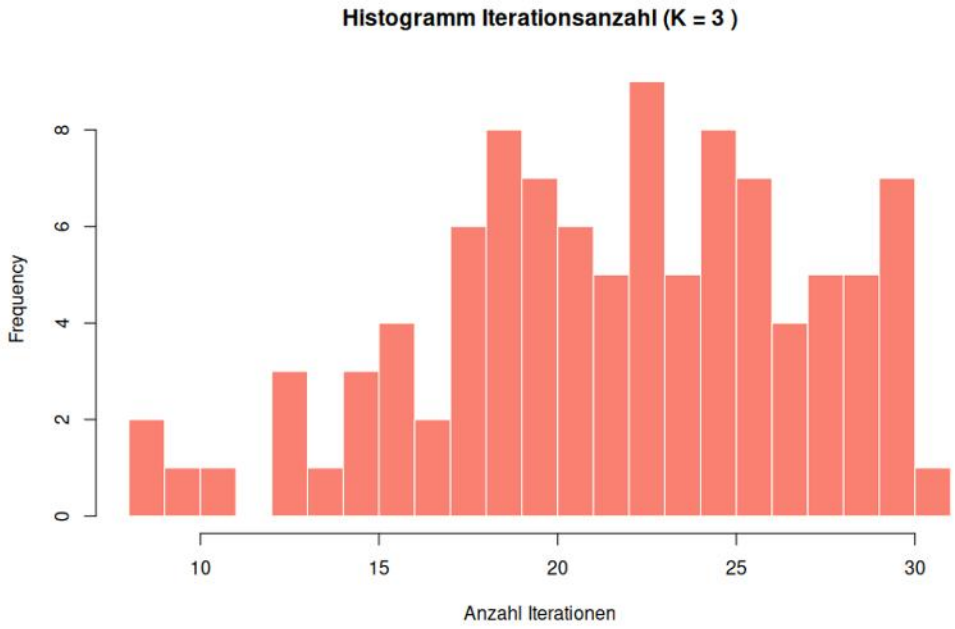


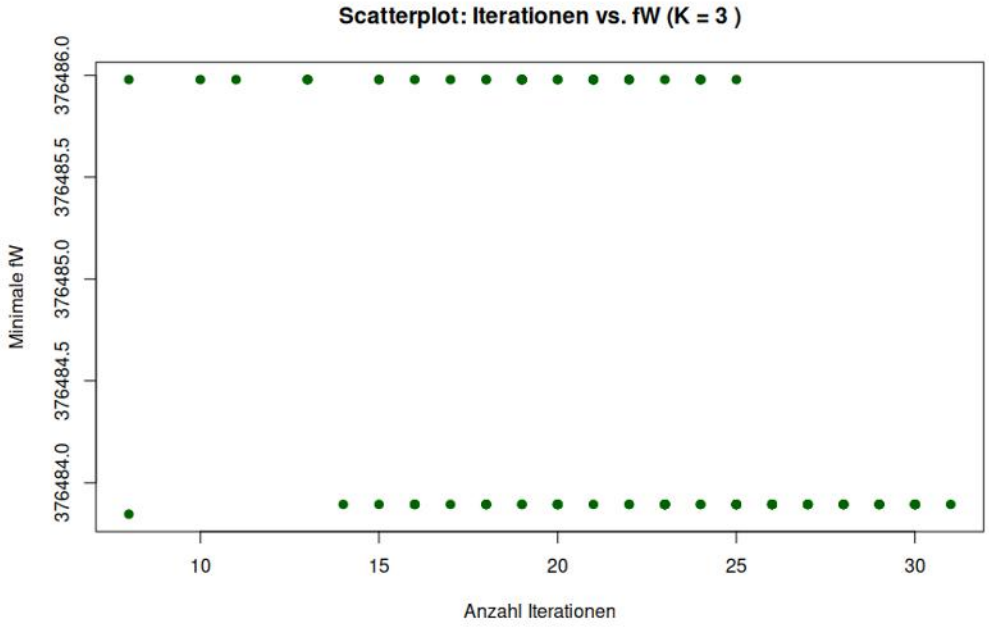
b)

Wir konnten unseren Algorithmus leider nur für K=3 zuende ausführen, weil es zu lange gedauert hat, der Ansatz für K=4 und K=5 ist aber im Code zu finden.









In den Plots der modifizierten Intra-Cluster-Varianzen sieht man wie auch schon bei K=2 Clustern, dass diese in Abhängigkeit der Iterationszahl monoton fallend ist. Dies ist ein Anzeichen dafür, dass der Algorithmus korrekt funktioniert. Die fW konvergiert im Plot wie auch bei K=2 Clustern relativ schnell, der Algorithmus läuft dann allerdings sehr oft noch mehr Iterationen weiter, als für die Konvergenz benötigt wurden.

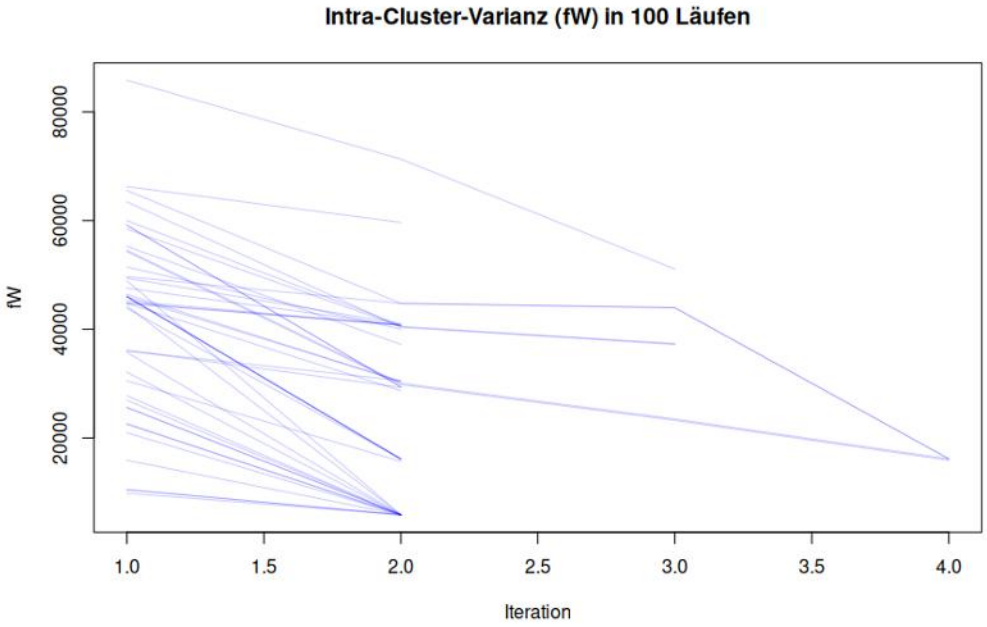
Das Histogramm der Werte der (mod.) Intra-Cluster-Varianzen zeigt wieder 2 Bins, die einen relativ geringen Abstand zueinander haben. Die Werte sind diesmal deutlich kleiner, aber immernoch 6-stellig. Die kleinere fW ist zum großen Teil wahrscheinlich darauf zurückzuführen, dass die Varianz der Datenpunkte innerhalb des

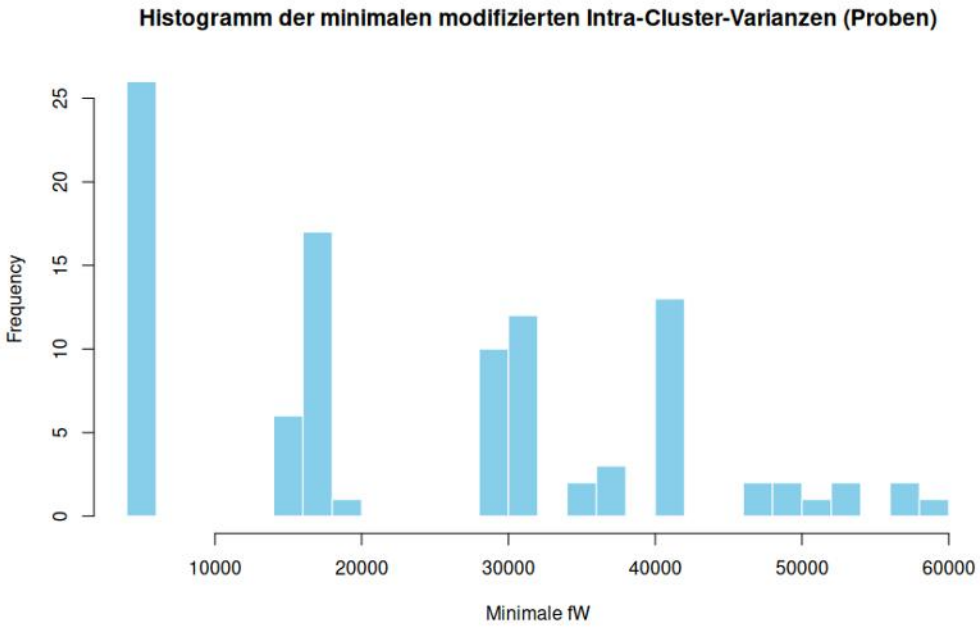
Clusters geringer ist, da sich die Punkte nun auf 3 Cluster aufteilen. Die Bins unterscheiden sich diesmal um einen einstelligen Wert. Außerdem sieht man, dass die fW-Werte nicht mehr nahezu gleichverteilt auf die Bins aufgeteilt sind.

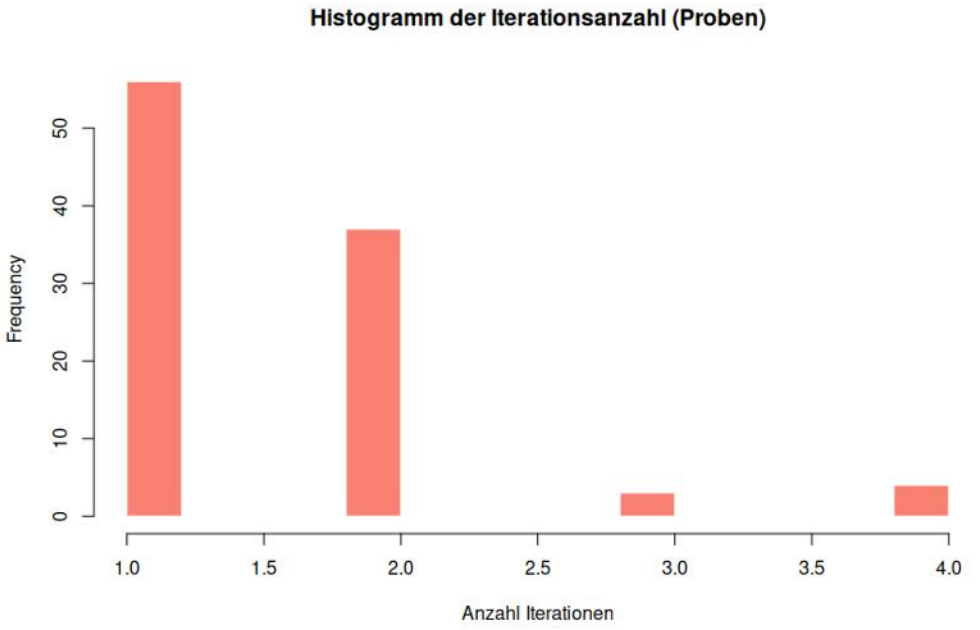
Das Histogramm über die Interationszahlen zeigt, dass nun maximal 10 Iterationen mehr gebraucht werden. Im Mittel werden auch mehr Iterationen gebraucht und eine Normalverteilung lässt sich nicht mehr erkennen, die Iterationszahlen liegen deutlich häufiger rechts des Mittelwerts.

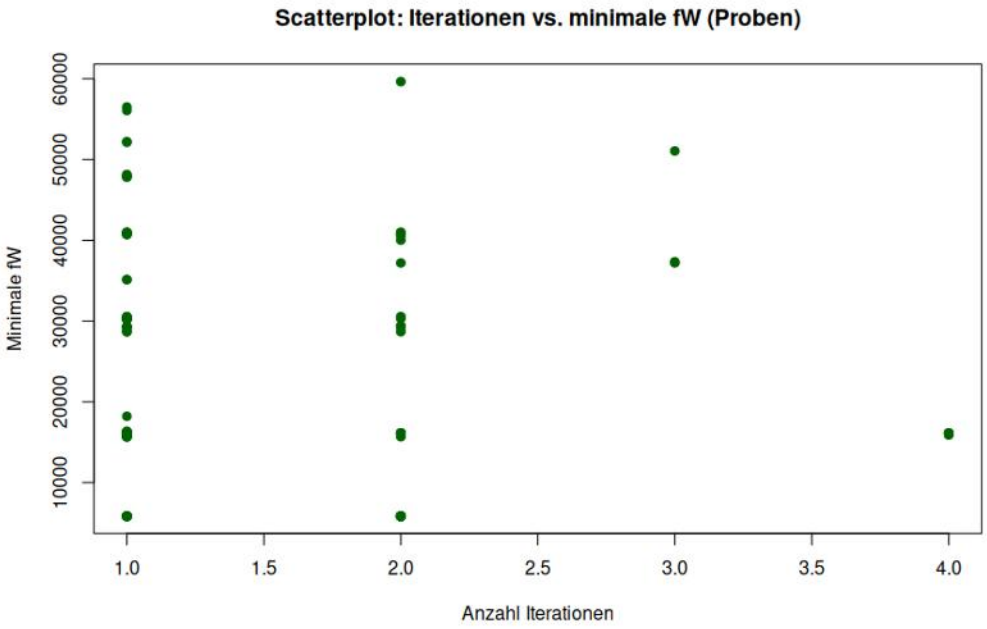
Auch der Scatterplot über fW in Abhängigkeit der Iterationszahl zeigt ein anderes Bild, hier ist die minimale fW eher geringer je mehr Iterationen gebraucht werden.

c)




Histogramm der minimalen modifizierten Intra-Cluster-Varianzen (Proben)
Frequency
0
5
10
15
20
25
10000
20000
30000
40000
50000
60000
Minimale fW


Histogramm der Iterationsanzahl (Proben)
Frequency
0
10
20
30
40
50
1.0
1.5
2.0
2.5
3.0
3.5
4.0
Anzahl Iterationen



Auch beim Clustering der Proben fällt die fW mit der Iterationszahl monoton, was erneut ein Indiz für die Funktionsfähigkeit des Algorithmus ist.

Im Histogramm der minimalen fW's sieht man im Gegesatz zum Clustering der Gene, dass die unterschiedlichen Initialisierungen des k-Means bei sehr unterschiedlichen fW's konvergieren. Dies könnte auf viele unterschiedliche Clustering-Lösungen abhängig von der Initialisierung hindeuten. Die Auftrittshäufigkeit der finalen fW sinkt je größer diese ist, was ein gutes Ergebnis ist, da diese minimiert werden soll. es gibt außerdem bestimmte ausgeprägte Peaks im Histogramm, was zu erwarten ist, da es bei 20 Datenpunkten nur sehr begrenzt viele Clusterings gibt, die Streuung der fW aber sehr hoch ist.

Das Histogramm der Iterationszahlen zeigt, dass der Algorithmus sehr schnell terminiert, meistens nach 1 oder 2 Iterationen.

Der Scatterplot lässt auf keinen Zusammenhang zwischen der Iterationszahl und der fW schließen.