Transkriptomanalyse

11. November 2026, Sommersemester 2025

Aufgabe 2

Da Aufgabe 9.2 vollständig gelöst wurde, sind im Folgenden auch die Ergebnisse für diese Aufgabe mit angegeben. Es werden also alle 7 Fälle des EM-Algorithmus dargestellt.

Für die gegebenen Parameter wurden folgende Werte gewählt:
$\underline{\pi}$ – Anteile der Datenpunkte mit Klasse k mit $k = 1, ..., K$ und $K = 2$
$\underline{\mu} = (-1, 1)^T$
$\underline{\sigma}$ – Standardabweichungen der Daten mit Berücksichtigung der Labels.

Als Startwerte für zu schätzende Werte wurden die wahren Werte unter Nutzung der Labels gaussverrauscht. Bei $\underline{\mu}$ war die Standardweichung des Gaussrauschens $0,1$, bei den anderen Parametern wurden Standardweichungen von $0,2$ gewählt. Die Klassenwahrscheinlichkeiten summieren sich zu 1.

Als Terminierungskriterium wurde eine Änderung der log-Likelihood von weniger als $1 \cdot 10^{-6}$ gewählt.

Allgemein lässt sich sagen, dass der EM-Algorithmus bei allen 7 Fällen innerhalb der 100 Initialisierungen bei unterschiedlichen Log-Likelihoods terminiert. Allerdings sind die Bereiche, in denen die pro Fall liegen sehr klein, sodass sich die Likelihoods nur in der 5.-7. Nachkommastelle unterscheiden. Dies sieht man in den Histogrammen der maximalen Log-Likelihoods und in den Scatterplots. Die Bereiche unterscheiden sich von Fall zu Fall.

In den Histogrammen der Iterationszahlen sieht man, dass je mehr Parameter zu schätzen sind, der Algorithmus auch mehr Iterationen braucht. Bei Fall 6, wenn $\underline{\pi}$ und $\underline{\sigma}$ zu schätzen sind, sind es allerdings nur geringfügig mehr Iterationen (im Mittel ca. 15), als wenn nur ein Parametervektor zu schätzen ist. Die Iterationszahlen folgen manchmal einer Normalverteilung (Fall 1, 2 und 6) und manchmal einer scheinbar linksschiefen Binomialverteilung (restliche Fälle).

Die Plots der Log-Likelihoods über die Iterationen zeigen, dass die Log-Likelihoods über alle Fälle fast immer innerhalb der ersten 5 Iterationen konvergieren und sich dann nur noch minimal ändern.

Die maximalen Log-Likelihoods scheinen keiner einheitlichen Verteilung zugehörig.

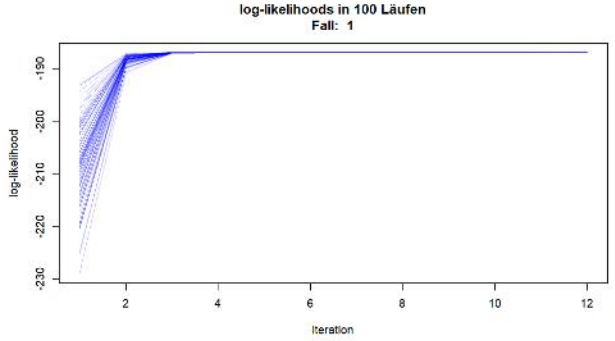
Bei Fall 7 gibt es bei den maximalen Log-Likelihoods 2 Ausreißer, wie man im zugehörigen Histogramm und im Scatterplot sehen kann. Im Scatterplot sieht man außerdem, dass diese finalen Werte deutlich am wenigsten Iterationen benötigt haben, hier könnte der Algorithmus vielleicht in lokalen Minima gelandet sein. Allerdings liegen die Ausreißer immer noch sehr dicht an den anderen Werten, wie oben bereits festgestellt wurde.

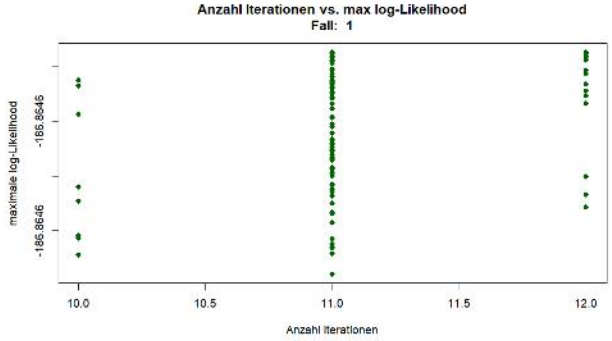
Bei den Scatterplots kann man nur bei Fall 1 und 2 einen schwachen Zusammenhang zwischen Iterationszahl und max. Likelihood erahnen, die Likelihoods streuen sehr stark pro Iterationszahl.

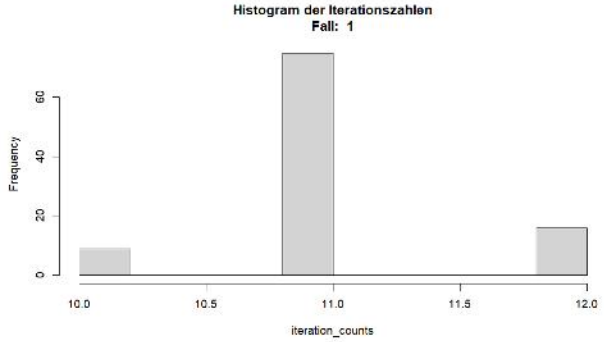
Man sieht deutlich, dass maximalen Log-Likelihoods des EM-Algorithmus besser werden, je mehr Parameter vom Algorithmus geschätzt werden. Bei einem zu schätzenden Parameter sind die maximalen Likelihoods noch höchstens ca. -184, bei zwei zu schätzenden Parametern sind die maximalen Likelihoods bereits zwischen

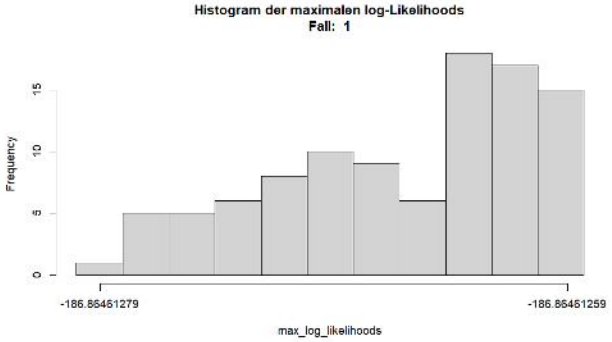
ca. -181,4 und -179,9. Sind alle Parameter zu schätzen, ist die Likelihood am besten mit ca. -179,8. Dies ist verwunderlich, da die gegebenen Parameter mit den wahren Parametern unter Berücksichtigung der Labels berechnet wurden. Da es das Ziel ist, die Likelihood zu maximieren, sollte also immer Fall 7 gewählt werden.

a) Fall 1: $\underline{\mu}$ zu schätzen



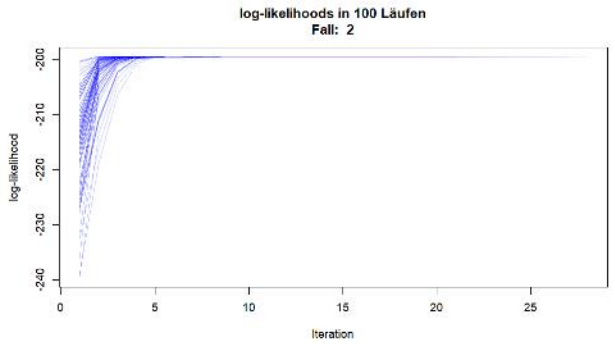


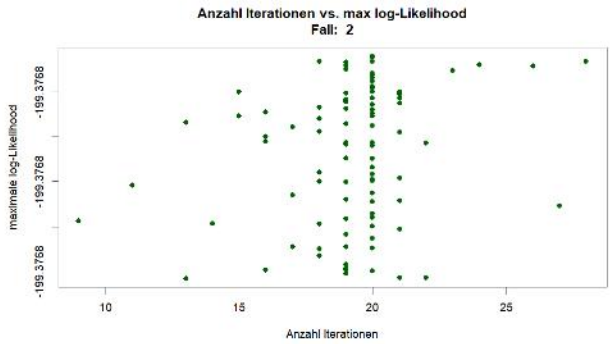


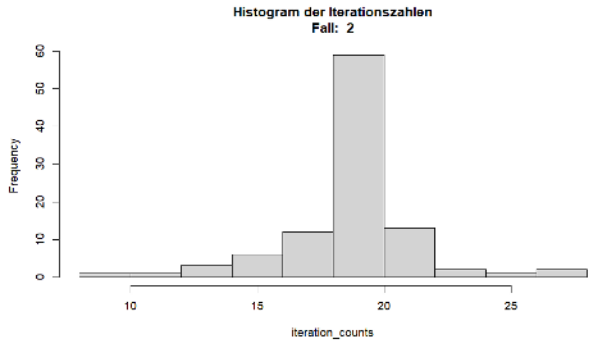


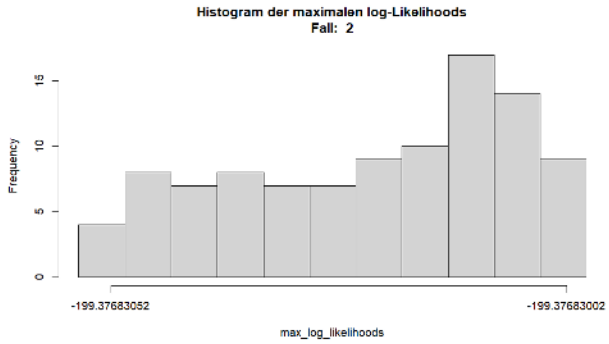
Der EM-Algorithmus erreicht in Fall 1 stets fast die gleichen Likelihoods bei Konvergenz

b) Fall 2: $\underline{\sigma}$ zu schätzen

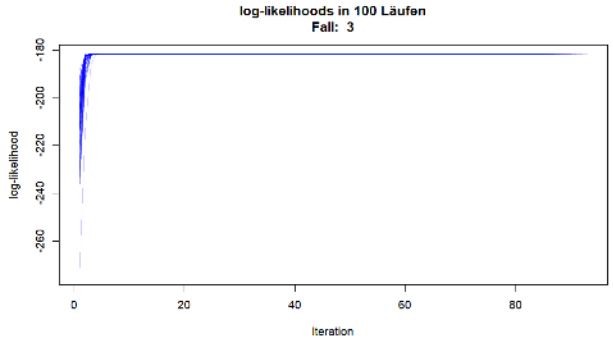


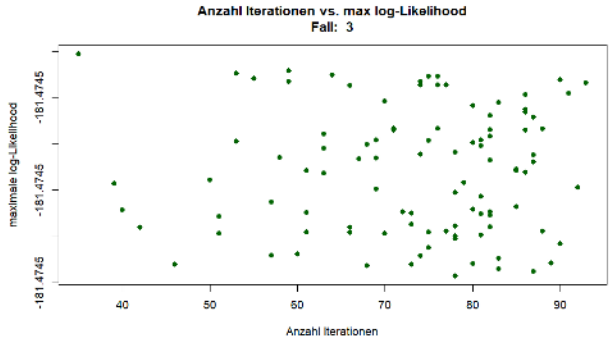


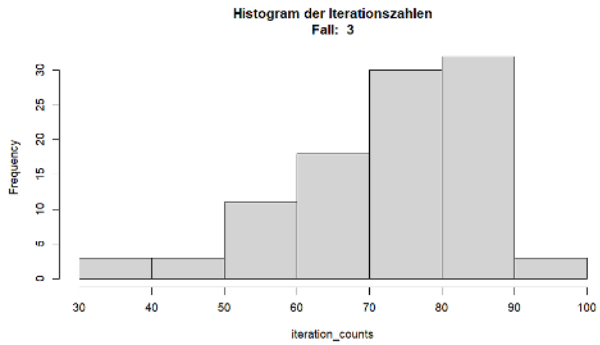


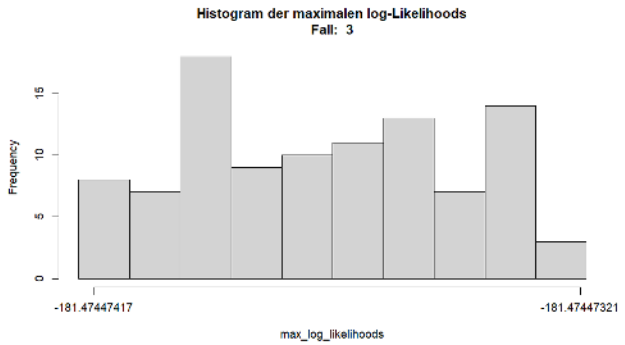


c) Fall 3: $\underline{\mu}$ und $\underline{\sigma}$ zu schätzen

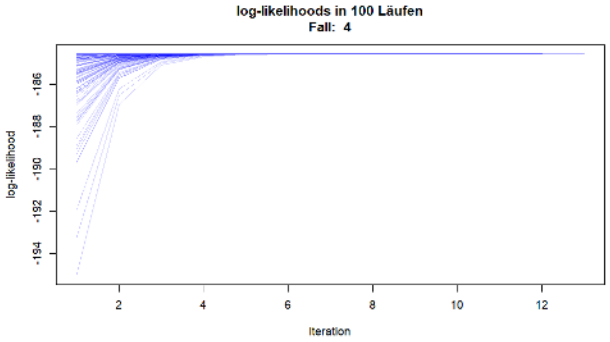


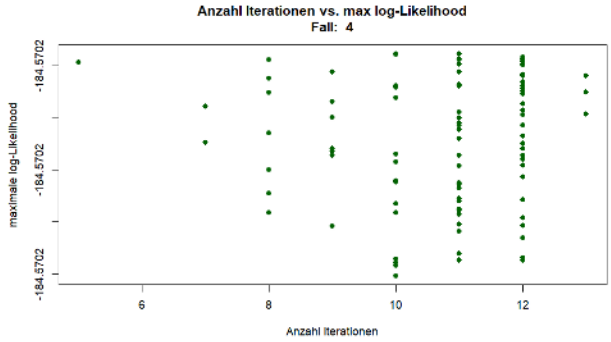


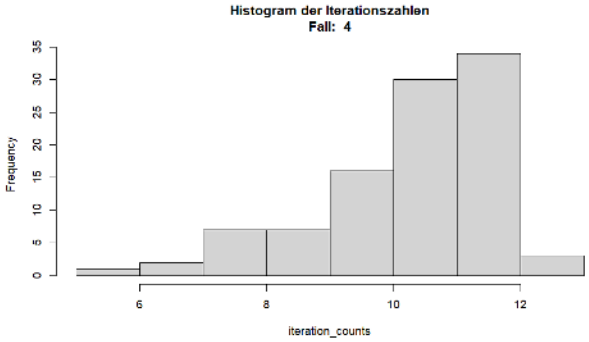


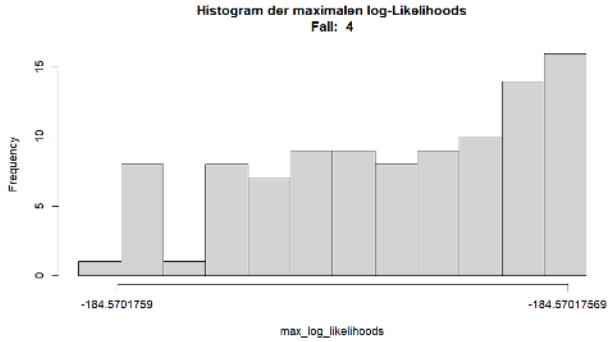


d) Fall 4: $\underline{\pi}$ zu schätzen

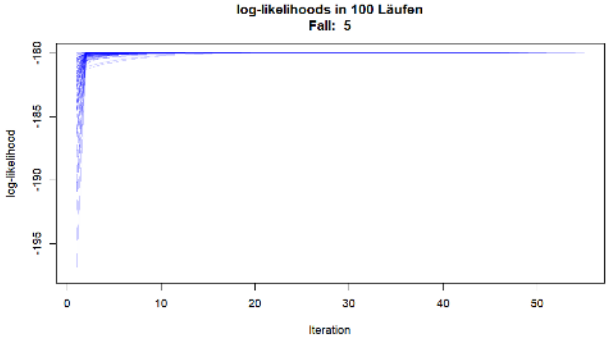


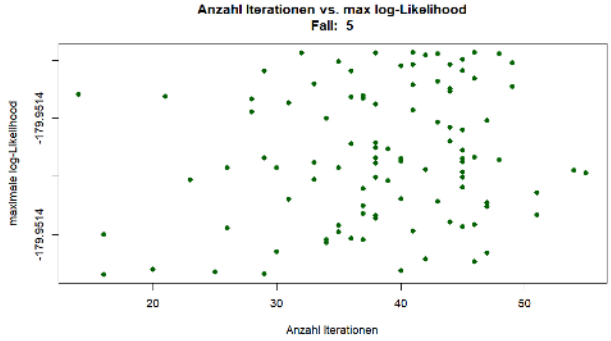


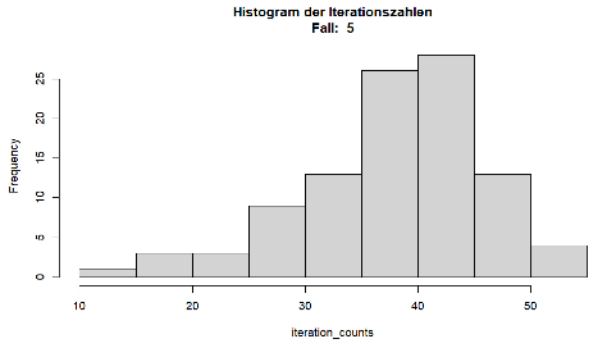


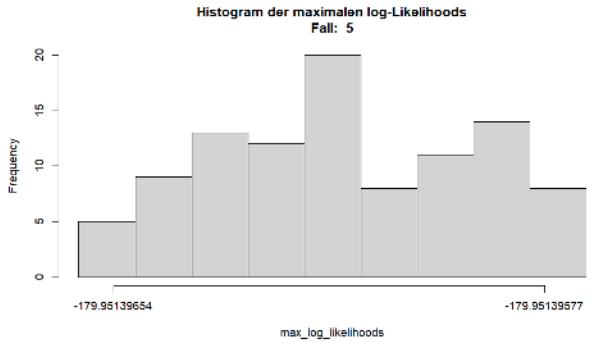


e) Fall 5: $\underline{\pi}$ und $\underline{\mu}$ zu schätzen

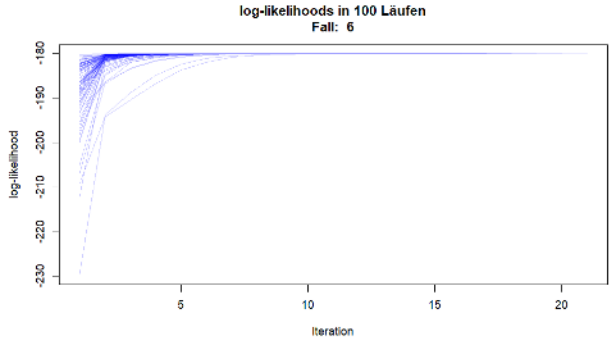


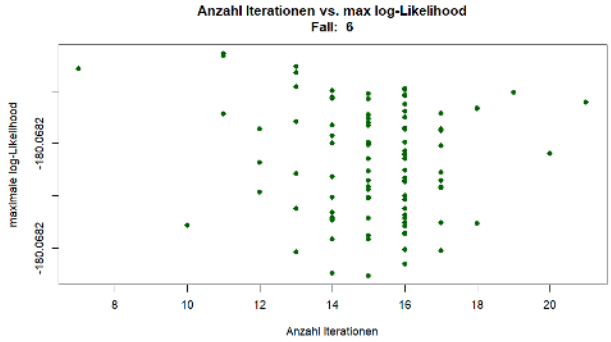


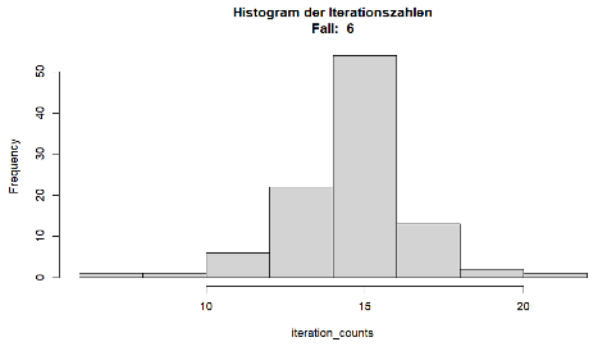


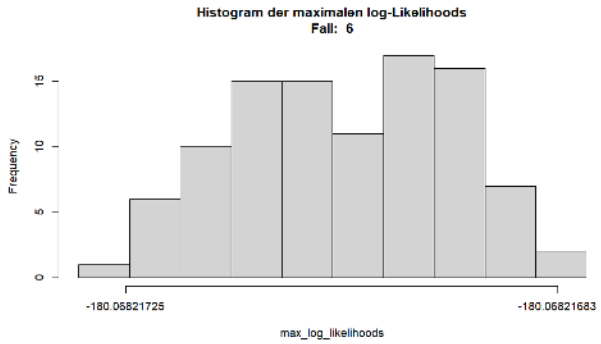


f) Fall 6: $\underline{\pi}$ und $\underline{\sigma}$ zu schätzen









g) Fall 7: alle Parameter zu schätzen

