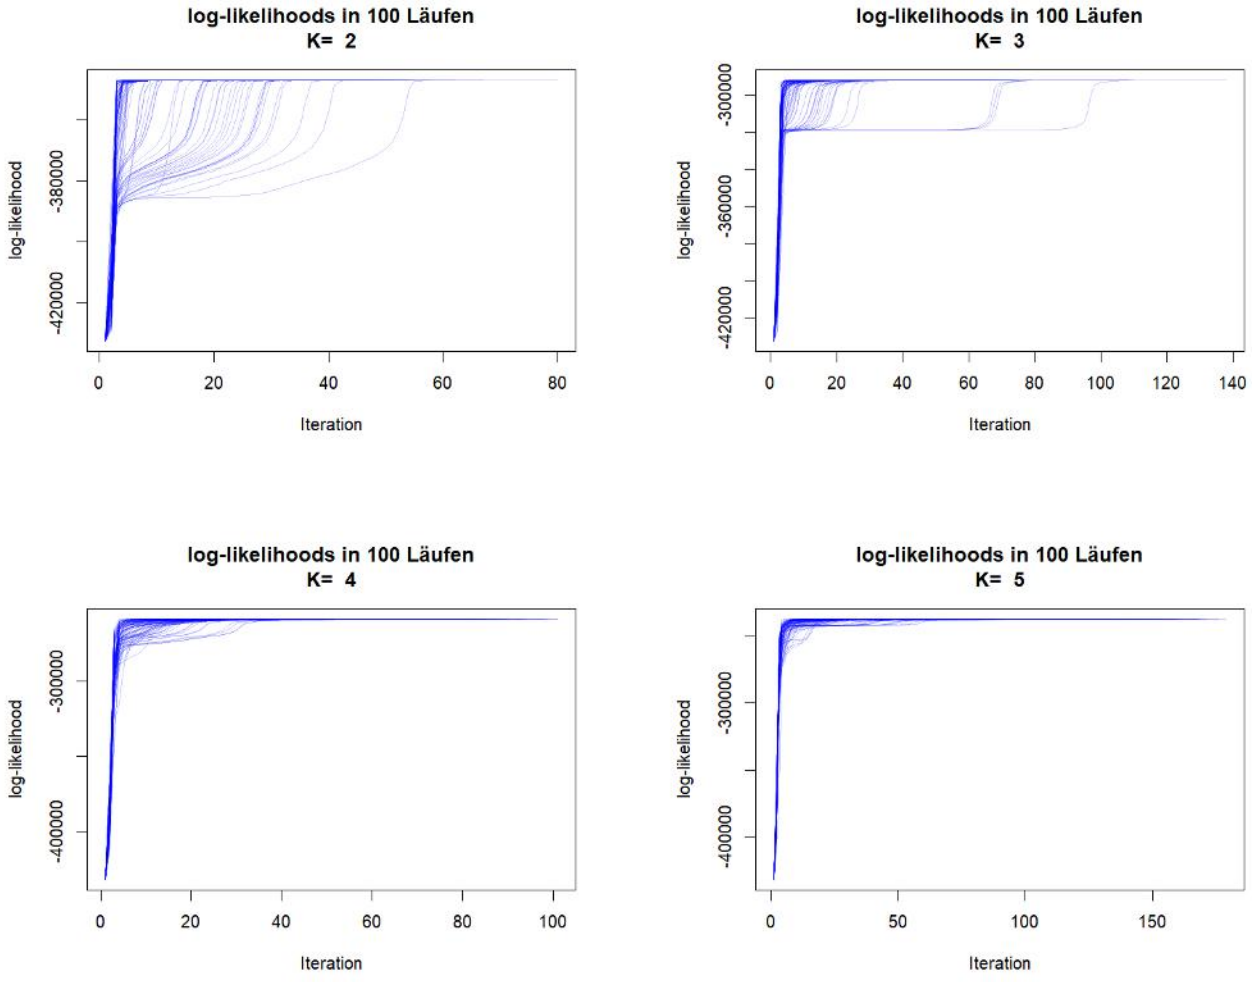
Transkriptomanalyse

12. November 2026, Sommersemester 2025

Aufgabe 2

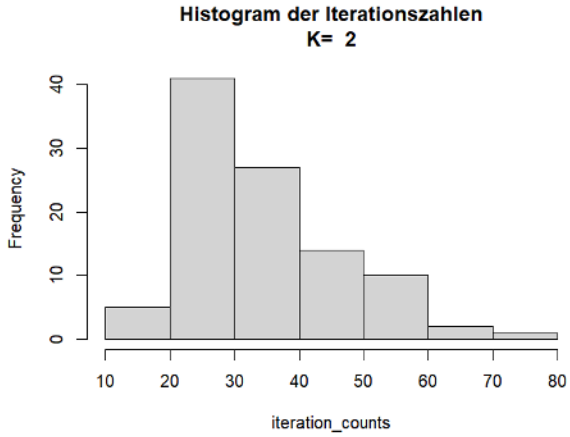
a)

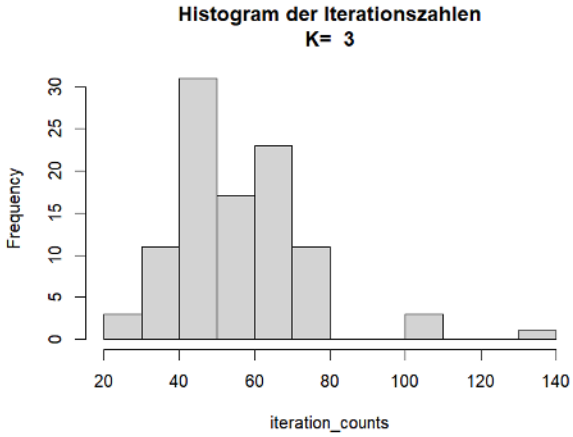
Log-Likelihood-Verläufe

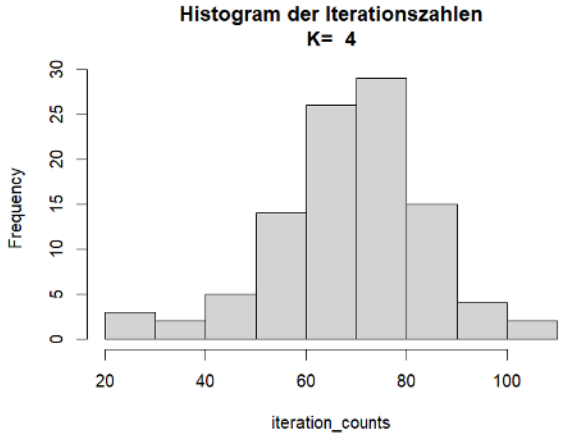


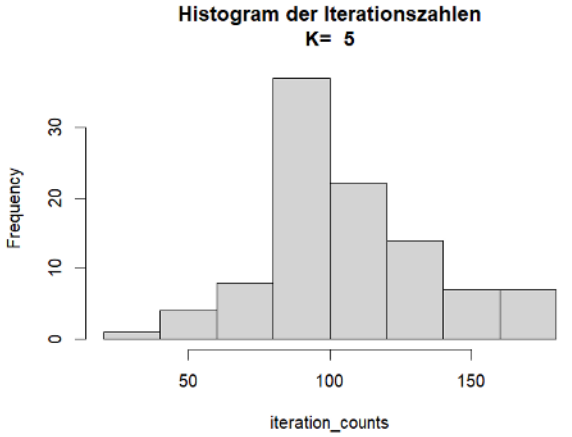
Beim Vergleich der Linienverläufe der Log-Likelihood über die Iterationen fällt auf, dass die Kurven für größere K zu Beginn steiler ansteigen. Obwohl die Initialisierung bei höheren K tendenziell ungünstiger ist, erreichen diese Modelle bereits nach wenigen Iterationen höhere Likelihood-Werte.

Histogramme der Iterationszahlen



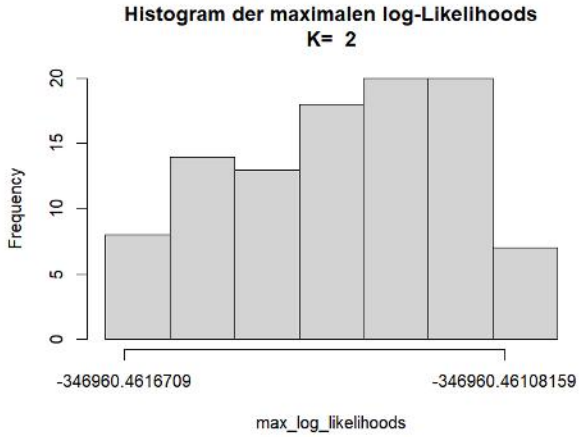


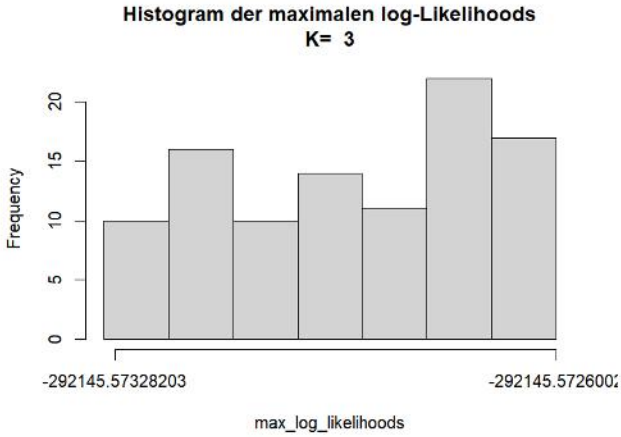


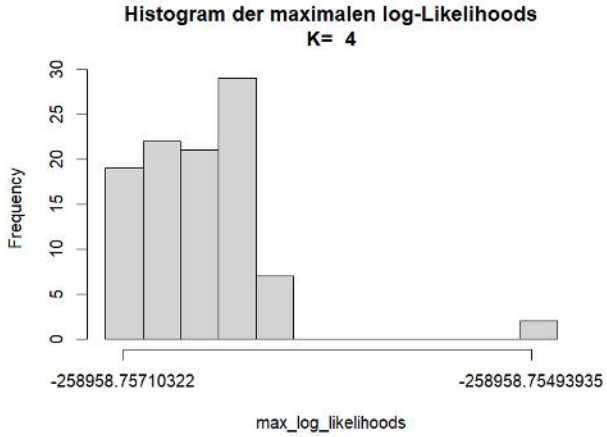


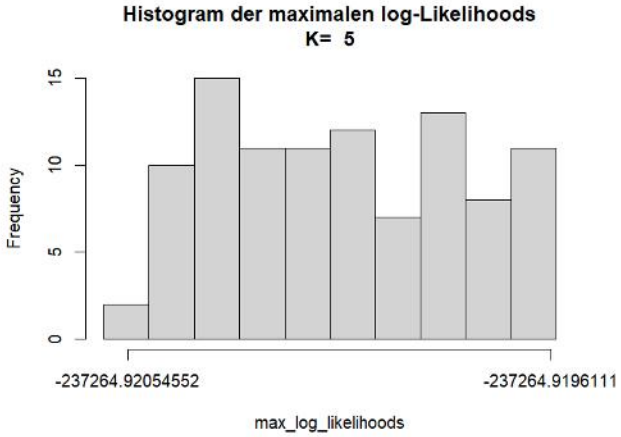
Die Histogramme zeigen, dass für ein höheres K tendenziell mehr Iterationen benötigt werden, bis der EM-Algorithmus konvergiert. Dies liegt daran, dass mit steigender Modellkomplexität auch mehr Parameter optimiert werden müssen.

Histogramme der Log-Likelihoods





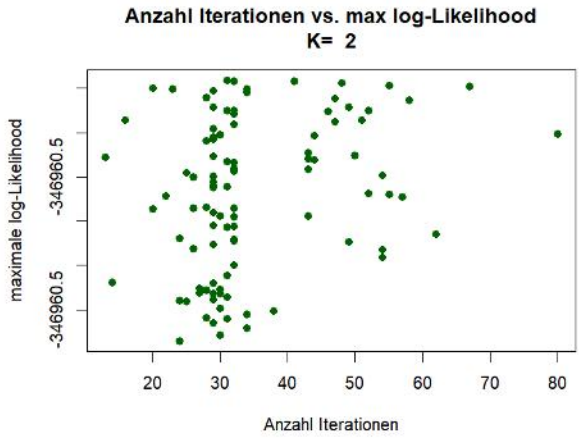


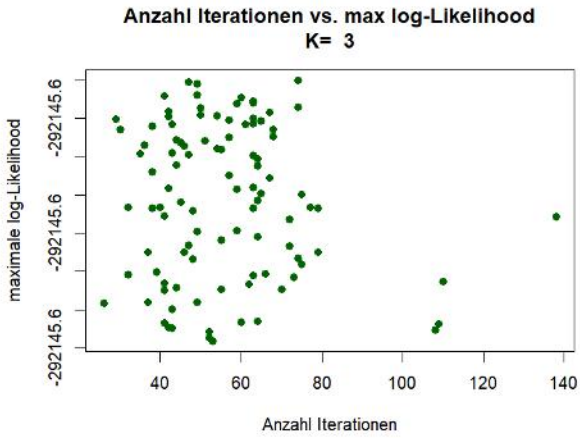


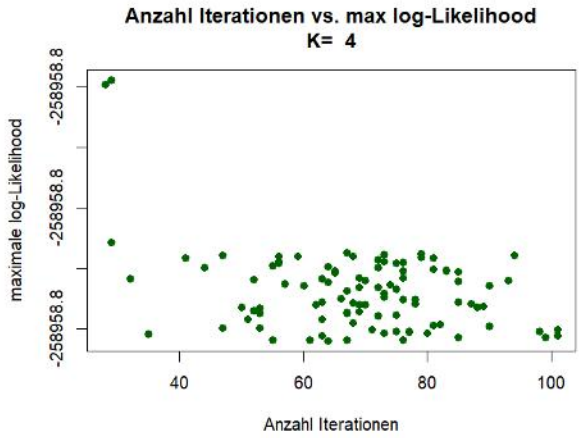
Bei den Histogrammen der maximalen Log-Likelihoods fällt auf, dass die Streuung der Ergebnisse mit zunehmendem K leicht zunimmt: Für K=2 schwanken die Endwerte erst ab der vierten Nachkommastelle, bei K=3 und K=4 bereits ab der dritten, wobei die Schwankung bei K=4 leicht ausgeprägter ist. Für K=5 zeigt sich eine Variabilität ab der zweiten Nachkommastelle. Dies deutet darauf hin, dass die maximale Log-Likelihood mit steigendem K tendenziell etwas empfindlicher gegenüber der Initialisierung wird.

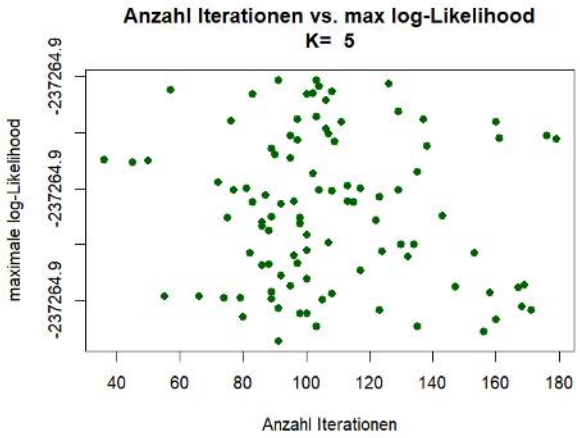
Gleichzeitig ist jedoch zu beobachten, dass der absolute Wert der Log-Likelihood mit wachsendem K deutlich ansteigt, was auf eine verbesserte Anpassung des Modells an die Daten hindeutet.

Scatterplots









BIC-Scores

Für K = 2 erhalten wir hier: −347341.2

Für K = 3 erhalten wir hier: −292716.7

Für K = 4 erhalten wir hier: −259720.3

Für K = 5 erhalten wir hier: −238216.8

Die BIC-Scores zeigen einen deutlichen Trend: Mit zunehmender Anzahl an Komponenten K verbessert sich der BIC-Wert kontinuierlich.

Da beim BIC gilt: je größer, desto besser, spricht dieser Verlauf dafür, dass Modelle mit mehr Komponenten die Daten besser beschreiben. Daher würde wahrscheinlich das Modell für K=5 am besten passen.